



Justicia

Bilan de livraison MVP

Périmètre contractuel

Client	Metaketing FZE
Objet	Intégration de papAI pour Justicia — assistant juridique à recherche augmentée (RAG)
Licence papAI	3 utilisateurs — 21 000 € HT / an
Développements	59 000 € HT (forfait)
Phase 1	Intégration CPU de RAGGER + RAFT dans papAI, premières briques RAG
Phase 2	Activation GPU, intégration LAFT, automatisation de la recherche juridique
Prérequis infra	Kubernetes, SSL, serveur Unix (vCores, RAM, stockage), Git, Docker

Ressources engagées

Moteur RAG & C-HAH ~22 j/h	Classification & templates ~5 j/h	Ingestion & OCR ~8 j/h	Interface ~7 j/h	Modèles & embeddings ~6 j/h	Benchmarking ~3 j/h	Infra & déploiement ~4 j/h
-------------------------------	--------------------------------------	---------------------------	---------------------	--------------------------------	------------------------	-------------------------------

Total : ~55 j/h



Proposition de valeur



Justicia

Assistant juridique — recherche augmentée sur corpus indexé

Ingestion multi-format + OCR

PDF, DOCX, e-mail, HTML — OCR
Tesseract pour les pièces numérisées.
Extraction de méta-données.

Retrieval hybride intelligent

Index dense FAISS + lexical BM25,
rerank par cross-encoder.
Recherche guidée par méta-données.

Multi-modèles & multi-profil

3 familles (Gemma, Llama, Mistral),
profils métier (juge, avocat, ...),
détection automatique de la tâche.

Fonctionnalités clés du MVP

5 templates de raisonnement

Pipeline C-HAH optimisé

Chaîne hyper-layered

Sélection auto. de la tâche

Micro-service indépendant

Réponses sourcées

- **Ingestion multi-format + OCR** — PDF, DOCX, e-mail, HTML, OCR Tesseract, extraction automatique de méta-données
- **Retrieval hybride intelligent** — FAISS + BM25, rerank cross-encoder, recherche guidée par méta-données
- **Multi-modèles & multi-profil** — 3 familles (Gemma, Llama, Mistral), profils métier, détection automatique de la tâche



Interface assistant

Paramètres

Profil

Juge

Modèle

Llama 3.1 — 8B Instruct

Base documentaire

faiss_Justicia

Pipeline

C-HAH — retrieval hybride

Température

0.10

Instruction de raisonnement

Analytique (fr)

Historique

Délais de recours — permis

Clause de non-concurrence

Responsabilité contractuelle

Exporter la conversation (JSON)

Justicia

Assistant juridique — recherche augmentée sur corpus indexé

Sources — Code de l'urbanisme L.600-1 ; CE, 3e ch., 15 mars 2024, n° 472.318

Analytique Dernière réponse 0,9 s

Vous Profil : Juge

Quels sont les délais de recours contre un refus de permis de construire ?

Justicia · Llama 3.1 — Analytique · 3 sources

Le recours contentieux contre un refus de permis de construire doit être exercé dans un délai de deux mois à compter de la notification de la décision au demandeur (art. R.600-1 et R.421-1 du code de l'urbanisme). En l'absence de notification régulière, le délai ne court pas. Un recours gracieux préalable proroge le délai de deux mois supplémentaires (art. R.421-2 C.JA).

Vous Profil : Juge

Et si le refus est implicite (silence de l'administration) ?

Justicia · Llama 3.1 — Analytique · 2 sources


En cas de décision implicite de rejet, le délai de deux mois court à compter de la date à laquelle la décision est réputée acquise. L'administration doit avoir accusé réception de la demande en mentionnant ce mécanisme (art. L.112-6 CRPA). Vérifiez dans les pièces du dossier si l'accusé de réception était conforme.

Le recours est-il suspensif dans ce cas ?

- **Zone de dialogue** — Réponse sourcée, template de raisonnement affiché, nombre de sources
- **Panneau paramètres** — Profil métier, modèle, pipeline C-HAH, instruction de raisonnement (5 templates FR/EN)
- **Gestion de sessions** — Historique persisté, export CSV / XLSX / JSON
- **Latence affichée** — Temps de réponse pour le suivi qualité



Pipeline C-HAH & raisonnement



- **Architecture Custom C-HAH** — chaîne de raisonnement hyper-layered, classification bayésienne automatique
- **5 templates** — Factuel, Analytique, Comparatif, Causal, Hypothétique (FR / EN)
- **3 familles de modèles** — Gemma (2B–9B), Llama (8B–70B), Mistral (7B–12B)



Traçabilité des sources & méta-données



Traçabilité des sources & méta-données

Chaque réponse cite les passages du corpus — extraction automatique des méta-données

Source 1 — Code de l'urbanisme, art. R.600-1

Pertinence : 0.94

« Le délai de recours contentieux à l'encontre d'une décision de non-opposition à une déclaration préalable ou d'un permis de construire court à l'égard des tiers à compter du premier jour d'une période continue de deux mois d'affichage ... »

Type : Code - Jurisdiction : — - Date : en vigueur

Source 2 — CE, 3e ch., 15 mars 2024, n° 472 318

Pertinence : 0.89

« Considérant que le délai de recours contentieux ne court qu'à compter de la date à laquelle la décision attaquée a été régulièrement notifiée au pétitionnaire, avec mention des voies et délais de recours ... »

Type : Jurisprudence - Jurisdiction : CE - Date : 15/03/2024

Source 3 — CRPA, art. L 112-6

Pertinence : 0.86

« L'administration est tenue de délivrer un accusé de réception pour toute demande adressée par un usager, mentionnant les délais et voies de recours ainsi que la date à laquelle la demande sera réputée acceptée ou rejetée. »

Type : Code - Jurisdiction : — - Date : en vigueur

3 passages retenus sur 10 documents — seuil de pertinence : 0.80 — méta-données extraites automatiquement

- **Extraits affichés** — Passages fondant la réponse avec score de pertinence
- **Méta-données** — Type, juridiction, date extraits automatiquement pour le smart retrieval
- **Auditabilité** — Chaque réponse vérifiable contre le fond documentaire



Profils, bases vectorielles & gouvernance

Profils, bases vectorielles & gouvernance

Mult-profil métier avec bases dédiées — administration et rôles

Bibliothèque de bases vectorielles (VDB)

Juge
Corpus décisionnel, jurisprudence administrative et judiciaire
Chargée

Avocat
Dossiers clients, notes de plaidoirie, jurisprudence de référence
Chargée

Notaire
Actes notariés, réglementation foncière et successorale
Prête

Personnalisé
Corpus défini par l'utilisateur (upload documents)
Prête

Rôles et accès

Rôle	Périmètre d'accès	Config.
Juriste / métier	Chat Justicia + corpus du profil attribué	Non
Admin données	Création VDB, indexation, ajout / retrait documents	Oui
Admin instructions	Modification des templates de raisonnement LLM	Oui
DSI / sécurité	Journaux d'accès, politique de rétention, clés API	Oui

Isolation par workspace
Chaque workspace dispose de ses propres bases vectorielles, historiques de conversation et droits d'accès. Interface de création et chargement de VDB intégrée.

En attente : données client pour constitution des VDB

- **VDB multi-profil** — Juge, avocat, notaire, personnalisé — avec interface de création et chargement
- **Rôles** — Juriste (utilisation directe), Admin données, Admin instructions, DSI
- **Isolation par workspace** — Bases, historiques et droits scindés par périmètre

Point bloquant : la constitution des VDB par profil nécessite les données documentaires du client, non encore transmises.



Investissement et cadre contractuel



Investissement et cadre contractuel

Licence papAI

3 utilisateurs — 21 000 € HT / an

Développements

59 000 € HT — forfait Phases 1 et 2

Phase 1 — CPU

RAGGER + RAFT intégrés à papAI

Premières briques RAG déployées

Livré

Phase 2 — GPU

Activation GPU, LAFT intégré à papAI

Inférence locale + recherche automatisée

En cours

Infrastructure mobilisée

- Serveur GPU dédié — inférence locale Llama 3 / Gemma / Mistral, travaux LAFT
- Serveur CPU / staging OVH — développement, tests, démo Streamlit
- Stockage — index FAISS, corpus de test, artefacts de benchmarking
- Réseau — SSL, CI/CD Bitbucket, configuration ports et accès

Charge humaine estimée : ~55 jours-homme

Moteur RAG, ingestion OCR, interface, embeddings, benchmarking, infra

- **Licence papAI** — 3 utilisateurs, 21 000 € HT / an
- **Développements** — 59 000 € HT forfait (Phase 1 CPU + Phase 2 GPU)
- **Infrastructure** — GPU dédié (inférence locale), serveurs staging OVH, CI/CD
- **Charge humaine** — ~55 jours-homme



Couverture de la roadmap MVP

Statut	Fonctionnalité	Détail
	Extraction de méta-données	Type, juridiction, date — extraction automatique
	Micro-service indépendant	Architecture découplée, déployable séparément
	Smart retrieval par méta-données	Filtres avancés (date, juridiction, type)
	Réponses sourcées	Citations, score de pertinence, traçabilité
	Bibliothèque VDB multi-profils	Juge, avocat, notaire — bases dédiées
	Interface création / chargement VDB	Création et sélection dynamique
	Constitution VDB sur données client	Données non transmises par le client
	Bibliothèque d'instructions LLM	Templates modifiables par l'admin
	5 templates de raisonnement	Factuel, Analytique, Comparatif, Causal, Hypothétique
	Templates bilingues FR / EN	Basculement par configuration
	Interface admin instructions	Modification du rôle et consignes modèle
	Sélection du modèle LLM	Choix parmi les modèles disponibles
	3 familles de modèles	Gemma (Google), Llama (Meta), Mistral
	Détection automatique de la tâche	Classification bayésienne du raisonnement
	Pipeline C-HAH optimisé	Custom pipeline — résultats accélérés
	Pipeline RAG complet	Chaîne hyper-layered chain-of-thoughts
	Recherche sémantique	Contexte, recherche dense + lexicale
	Ingestion multi-modale	PDF, DOCX, HTML, e-mail, PPTX, CSV
	OCR	Tesseract pour pièces numérisées
	Raisonnement multi-modal	Texte + image
	ElasticSearch	Écarté — remplacé par FAISS + BM25
	Base relationnelle méta-données	Écarté — intégrées dans l'index vectoriel

